



EGE ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ



DOKTORA TEZ İZLEME RAPORU-3

A. TEZ PROJESİNE İLİŞKİN GENEL BİLGİLER

A.1 Tezin Adı: Biyokütleden Elde Edilen Biyoyağ Kompozisyonunun Makine Öğrenmesi ile Tahmini ve Model Öngörülü Kontrol Tabanlı Süreç Optimizasyonu

A.2 Tez Danışmanı ve Yürütücüsü

- a. Tez Danışmanı:** Prof. Dr. Hayati OLGUN
- b. Tez İzleme Komitesi:** Prof. Dr. Hayati OLGUN, Prof. Dr. Harun Kemal ÖZTÜRK,
Dr. Öğretim Üyesi Özben KUTLU
- c. Tez Yürütücüsü:** Orhun UZDİYEM

A.3 Tezin Yürütüldüğü Anabilim Dalı: Güneş Enerjisi Enstitüsü -
Enerji Teknolojisi Bilim Dalı

A.4 Tezin Yürütülmesinde İş birliği Yapılacak Kurum ve Kuruluşlar: -

A.5 Tezin Başlangıç ve Bitiş Tarihi: 02/01/2024 - 02/01/2026

B. TEZİN PLANLANMASI VE YAPILAN ÇALIŞMALAR

B.1 Tezin Amacı:

Bu tez çalışmasında biyokütlenin yavaş pirolizi sırasında ortaya çıkan ürün biyoyağın değerlendirilerek katma değerli ürüne dönüştürülmesi üzerinde durulmuştur. Biyoyağ, petrol türevlerine alternatif olabilecek değerli hidrokarbonları içeren bir üründür. Ancak, biyokütlenin türüne ve proses koşullarına bağlı olarak biyoyağ içeriği de oldukça değişkenlik gösterir [Zhang et al, 2017]. Bu durum, biyoyağın işlenmesi ve değerlendirilmesi süreçlerini karmaşıktırmaktadır. Çünkü biyoyağın işleneceği proses parametrelerinin belirlenmesinde temel etken biyoyağ kompozisyonudur. Ayrıca biyoyağ kalitesinin düşük olma ihtimali de uygulama alanını daraltmaktadır [Keskin and Duman, 2020]. Bu nedenlerle yükseltme reaksiyonları için pahalı proseslere ihtiyaç duyabilecek biyoyağın nasıl değerlendirileceğine karar vermek zorlaşmaktadır.

Biyoyağ, değerli hidrokarbon içeriği ile gerek biyoyakıt gerek karbon nanomalzeme gerekse de karbon fiber gibi polimerlere dönüştürülebilen değerli bir ara üründür. Ancak kompozisyonunun kaynağa bağlı olarak farklılık göstermesi ve dolayısıyla da maliyetli yükseltgenme/indirgenme proseslerine ihtiyaç duyması sebebiyle ticari piroliz sistemlerinde verimli bir şekilde değerlendirilememektedir.

Bu çalışmanın temel amacı, biyokütleden elde edilen biyoyağ içeriğini tahmin edebilen bir yapayzeka modeli geliştirmek ve bu tahminler doğrultusunda biyoyağın değerlendirildiği prosesin parametrelerinin belirlenmesine yardımcı olacak bir model öngörülü kontrol (MÖK) senaryosu geliştirmektir.

B.2 Dönem İçerisinde Yapılan Çalışmalar:

Çalışmanın bu aşamasında öncelikle literatür taramasına devam edilmiş ve 7 adet yeni çalışmadan toplanan veriler veritabanımıza eklenerek veri sayısı genişletilmiştir. Yeni eklenen verilerle beraber biyokütle özellikleri, piroliz koşulları ve biyoyağ kompozisyonunun yer aldığı veri adedi toplamda 48'den 70'e çıkarılmıştır.

Modak ve arkadaşları (2023), karışık pişmiş gıda atığı ile üç farklı piroliz sıcaklığı ile çalışmış ve 400 °C'de en yüksek $\approx$ %45 bio-yağ verimine ulaşıldığını, 500 °C'de ise aromatik fraksiyonun $>$ %60'a çıktığını raporetmıştır. Bordoloi ve arkadaşları (2016), tatlı su mikroalgı *Scenedesmus dimorphus* biyokütlesini 500 °C'de tek bir piroliz sıcaklığında karakterize etmişlerdir; bio-yağ verimi %39,6 olup n-hekzan, toluen, etil asetat ve metanol alt fraksiyonlarına ayrılmış, yüksek protein kökenli N-bileşiklerine dikkat çekilmiştir. Yağ palmyesi (*Elaeis guineensis*) boş meyve salkımları (EFB) biyokütlesinin 500 °C'de tek bir piroliz sıcaklığında dönüştürülmesi, Sukiran ve arkadaşları (2009) tarafından gerçekleştirilmiştir; %42,3'e varan bio-yağ verimi ve 20–21 MJ kg⁻¹ YİD (HHV) elde edilmiş, FT-IR analizinde fenolik-ketonik zenginlik ortaya konmuştur. Mullen ve arkadaşları (2010), arpa sapı, arpa kabukları ve damıtma işlemi sonucunda elde edilen kurutulmuş küspe ve çözünür bileşenler (DDGS) olmak üzere üç farklı arpa biyokütlesini 500 °C'lik tek bir hızlı piroliz sıcaklığında incelemişlerdir; bio-yağ verimi %42–50 aralığında, DDGS kökenli yağın kuru bazda 30 MJ kg⁻¹ üzeri YİD ile daha enerjik olduğu, ancak bütün yağların rafine edilmeden raf ömrü sınırlı kaldığı belirtilmiştir. 2019 yılında Chukwuneke ve arkadaşları, *Swietenia macrophylla* (maun) odun atığını 450 °C'lik tek bir piroliz sıcaklığında işleyerek elde ettikleri biyoyakıtın fizikokimyasal analizini gerçekleştirmişlerdir; maksimum bio-yağ verimi %69,5,

viskozite $4,6 \text{ mm}^2 \text{ s}^{-1}$ ve $29,5 \text{ MJ kg}^{-1}$ YİD ölçülmüş, GC-MS’de 24 önemli aromatik-alifatik bileşik tanımlanmıştır. 2009 yılında Khor, Lim ve Zainal, yağ palmyesi boş meyve salkımı liflerini tek bir $600 \text{ }^{\circ}\text{C}$ ’lik yavaş piroliz sıcaklığında işleyerek elde ettikleri biyoyakıtı karakterize etmişlerdir; yalnızca %13 yağ verimine karşın $31,4 \text{ MJ kg}^{-1}$ YİD, pH 3,6 ve $\text{CH}_{1.41}\text{N}_{0.03}\text{O}_{0.24}$ ampirik formülü rapor edilmiş, yüksek asit sayısı ($103 \text{ mg KOH g}^{-1}$) nedeniyle depolama/taşıma korozivitesine vurgu yapılmıştır.

2025 yılında Sampaio ve arkadaşları, biyokütle pirolizindeki ekstraktiflerin bio-yag bileşimine etkisini inceledikleri kapsamlı derleme çalışmalarında; palmye kabuğu ($500 \text{ }^{\circ}\text{C}$), okaliptüs cipsi ($550 \text{ }^{\circ}\text{C}$), çam talaşı ($500 \text{ }^{\circ}\text{C}$), sisal kalıntısı ($500 \text{ }^{\circ}\text{C}$), muz yaprakları ($500 \text{ }^{\circ}\text{C}$), bambu ($550 \text{ }^{\circ}\text{C}$), şeker kamışı posası ($480 \text{ }^{\circ}\text{C}$), pirinç sapı ($550 \text{ }^{\circ}\text{C}$), mısır sapı ($500 \text{ }^{\circ}\text{C}$), mısır koçanı ($500 \text{ }^{\circ}\text{C}$), hindistancevizi kabuğu ($500 \text{ }^{\circ}\text{C}$) ve mahua tohumu ($525 \text{ }^{\circ}\text{C}$) gibi on dört farklı biyokütleyi inceleyip karşılaştırmışlardır. Derleme, ekstraktif-zengin hammaddelerde iki fazlı yağ oluşumu, sisal kalıntısında görülen düşük $\text{O/C} = 0,16$ gibi değerlerin YİD artışına yol açtığını göstermiş; Cu ve Mn gibi inorganiklerle etkileşen ekstraktiflerin aktivasyon enerjisini $10\text{--}25 \text{ kJ mol}^{-1}$ düşürdüğünü ve asetik/formik asit üretimini katalitik olarak artırdığını ortaya koymuştur. Ayrıca lipofilik-hidrofilik denge, fenolik dağılımı ve faz ayrımını yönlendiren ana unsur olarak tanımlanmış, süreç optimizasyonu için kinetik model önerileri sunulmuştur. Çalışmada, ekstraktif içeriklerin artışıyla bio-yag verimi ve kimyasal dağılım (fenoller, ketonlar, asitler, furanslar vb.) arasındaki ilişkiler detaylıca tartışılmış; özellikle O/C ve H/C oranları ile yüksek ısı değerindeki (HHV) değişimler ortaya konmuştur. Bu derleme, ekstraktiflerin piroliz aktivasyon enerjisini düşürerek reaksiyon mekanizmalarını nasıl modüle ettiğine dair bilinçli modellemelere ve sürdürülebilir biyoyakıt üretim süreçlerinin optimizasyonuna ışık tutmaktadır.

Veritabanındaki verinin makine öğrenmesi öncesi işlenmesi kodları için iki yeni yaklaşım geliştirilmiş ve bu yeni geliştirilen yaklaşımlarla veriler işlenmiştir. Farklı makine öğrenmesi yöntemlerinin kodları yazılmış ve işlenmiş veri setleri üzerinde denenerek sonuçlar incelenmiştir. Son olarak ta biyoyağın hammadde olarak kullanılacağı prosesler için bir literatür taraması yapılmıştır.

B.2.1 Veri önışleme algoritması

Çok fazla sayıda farklı kaynaktan veri toplanmış olduğu için hem biyokütle özelliklerinde hem piroliz koşullarında hem de biyoyağ kompozisyonu değerlerinde çok sayıda eksik bilgi

bulunmaktadır. Önceki denemelerimizde eksik bilgilerin tamamlanması için ortalama değer ile doldurma yaklaşımı denenmişti. Bu dönem içinde yapılan çalışmada eksik bilgiler ile ilgili farklı yaklaşımlar düşünülmüş ve denenmiştir.

Öncelikle eksik bilgi bulunan her bir değişken için farklı yaklaşım izlenmesi gerektiği düşünülmüştür.

- i. O/C ve H/C değerleri eksik olan satırlar için bu değerler C, H ve O değerleri kullanılarak hesaplandı
- ii. Volatiles, Fixed Carbon ve Lignin değerlerinde eksik olan satırlar için bu değerler KNNImputer yöntemi kullanılarak dolduruldu. Bu değerlerin belirleyici değerleri olarak O/C, H/C, S ve Ash değerleri kullanıldı.
- iii. HHV değerlerinde eksik olan satırlar için bu değerler KNNImputer yöntemi kullanılarak dolduruldu. Bu değerlerin belirleyici değerleri olarak O/C, H/C, S, Ash, Holoselülöz ve Lignin değerleri kullanıldı.
- iv. Selülöz ve Hemiselülöz değerlerinde eksik olan satırları için bu değerler KNNImputer yöntemi kullanılarak dolduruldu. Bu değerlerin belirleyici değerleri olarak O/C, H/C, S, Ash ve HHV değerleri kullanıldı. Bu satırlarda Holoselülöz değeri mevcut ise çıkan değerler toplamı Holoselülöz değerini verecek şekilde ölçeklendi.
- v. Holoselülöz değerleri eksik olan satırlar için bu değerler Selülöz ve Hemiselülözdeğerleri kullanılarak hesaplandı.
- vi. N değerlerinde eksik olan satırlar ortalama değer ile dolduruldu
- vii. Kesikli tepkimelerde bulunan Duration ve sürekli tepkimelerde bulunan ResidenceTime değerleri aynı aralığa (0 ile 1 arası) ölçeklendikten sonra tek bir değişken olarak kullanıldı.
- viii. Katalizör özellikleri eksik olan satırlar için bu değerler NULL (tanımsız) olarak işaretlenmiştir.
- ix. Biyoyağ kompozisyonu değerlerinde eksik olan satırlar için de bu değerler NULL (tanımsız) olarak işaretlenmiştir.

Biyoyağ kompozisyonu değerlerinde her çalışmada farklı kimyasallar için NULL değerleri bulunması sonucu veri setinin hazırlanması konusunda iki farklı yaklaşım düşünülmüştür.

B.2.1.1 Birleşik veri seti yaklaşımı

Bu yaklaşımda, bütün veriseti bir bütün olarak işlenmiştir. Bu sayede her bir kimyasal için makine öğrenmesi modeli eğitilirken bütün veriseti kullanılmıştır. Ancak bu yaklaşımda biyoyağ içeriği değerlerinde çok fazla NULL değer bulunması modelin başarısını olumsuz yönte etkileyen bir unsurdur.

B.2.1.2 Ayrıştırılmış veri seti yaklaşımı

Bu yaklaşımda, biyoyağda bulunan her bir kimyasal grubu için ayrı bir veriseti hazırlanmıştır. Veriseti kimyasallara göre ayrıştırılırken o kimyasal için NULL değer bulunan satırlar çıkartılmıştır. Bu sayede NULL değerlerden arınmış verisetleri kullanılmıştır. Ancak bu yaklaşımda makine öğrenmesi daha az sayıda örnek içeren verisetleriyle yapılmak zorunda kalmıştır. Bu da eğitilen modelin kapsayıcı özelliğini olumsuz etkilemektedir. Ayrıca kimyasal grupların birbirlerinden bağımsız eğitilmesi de toplamı 1 değerinden uzak kompozisyon değerleri öngörülmesine neden olabilmektedir.

B.2.2 Makine öğrenmesi yöntemleri

Bu bölümde, biyokütle ile biyoyağ çıktıları arasındaki ilişkileri kestirmek amacıyla kullandığımız Random Forest, XGBoost, LightGBM, CatBoost ve Doğrusal Regresyon yaklaşımlarının altındaki temel algoritmik ilkeler ayrıntılı olarak ele alınmaktadır. Amaç, her yöntemin nasıl çalıştığını ve hangi senaryolarda üstünlük sağladığını açıklığa kavuşturmaktır.

B.2.2.1 Random Forest (Rastgele Orman)

Random Forest (Rastgele Orman) algoritması, eğitim kümesinden tekrarlı geri koymalı örnekleme ile çok sayıda alt küme (bootstrapped set) oluşturur; her alt kümede sınırsız veya sınırlı derinlikte CART karar ağaçları yetiştirilir ve bölünme, sınıflamada Gini saflığı düşüşü ya da regresyonda SSE düşüşü kriterine göre seçilir. Her düğümde, tüm özelliklerin karekökü kadar rastgele seçilen aday değişkenler üzerinden bölünme yapılır; bu, ağaçlar arasındaki korelasyonu azaltarak ansambl çeşitliliğini artırır. Sonuçta, regresyonda ağaçların tahminlerinin aritmetik ortalaması, sınıflamada ise çoğunluk oyu kullanılarak nihai tahmin elde edilir. Çoklu çıktı uyumlamada MultiOutputRegressor her hedef değişken için ayrı bir

orman kurar; bu paralel eğitimle hız kazandırsa da korele hedefler arasındaki bilgi paylaşımını engelleyerek potansiyel bilgi kaybına yol açabilir. Algoritmanın avantajları arasında düşük varyans ve yüksek genelleme (bagging hatayı azaltır), parametre hassasiyetinin görece düşük olması ($n_estimators$ ve max_depth ana kontrol noktalarıdır) ve Gini ya da permütasyon temelli değişken önem skorlarıyla açıklanabilirlik yer alır. Buna karşılık, çok sayıda ağaç bellek kullanımını önemli ölçüde artırabilir ve bağımsız ağaçlar derin korelasyonlu veya çok karmaşık örüntüleri yakalamakta boosting kadar başarılı olamayabilir.

B.2.2.2 XGBoost (eXtreme Gradient Boosting)

XGBoost (eXtreme Gradient Boosting), artımlı öğrenme yaklaşımıyla ardışık ağaçlar ekleyerek önceki ansamblın artık hatalarını minimize etmeye odaklanır. Her iterasyonda kayıp fonksiyonu ikinci dereceden Taylor açılımıyla (birinci türev g ve ikinci türev h) yaklaşık hesaplanır; bu sayede optimum yaprak skorları kapalı formülle bulunur. Ağaç karmaşıklığı hem $L1$ hem de $L2$ düzenleme terimleriyle cezalandırılarak aşırı uyum azaltılır. Seyrek bilinçli tasarımı, eksik (NA) değerler için otomatik yön seçimi ve blok yapılı bellek yönetimi sayesinde büyük veri kümelerinde verimli çalışır.

Öne çıkan mekanizmalar arasında her ağacın katkısını η öğrenme oranıyla çarpan shrinkage; daha küçük η değerlerinin daha fazla ağaç ama nihai doğrulukta iyileşme getirmesi; sütun örnekleme ile her iterasyonda rasgele özellik alt kümesi seçerek çeşitlilik eklenmesi; ve büyük veri için hızlı ve dayanıklı ayırım noktası belirleyen ağırlıklı kantitatif taslak (weighted quantile sketch) yer alır.

Avantaj olarak, özellikle heterojen ve karmaşık ilişkili veri setlerinde yüksek R^2 performansı gösterme eğilimindedir. Dezavantajı ise hiperparametre duyarlılığının fazla olması— max_depth , min_child_weight , $subsample$ gibi parametrelerin kapsamlı optimizasyonu gereklidir.

B.2.2.3 LightGBM

LightGBM, sürekli değişkenleri önceden tanımlı k kovana özetleyen histogram tabanlı ayırma ile split aramalarını $O(\#bin)$ zamanına indirir. Ağaç büyümede “leaf wise” (best-first) stratejiyle en yüksek bilgi kazancı sağlayan yapraktan derine inerek aynı derinlik stratejisine göre daha az ağaçla hatayı düşürür. Büyük veri kümelerinde hesaplamayı hızlandırmak için GOSS (Gradient Based One-Side Sampling) ile büyük gradyana sahip örnekleri korur, küçük

gradyanlıları alt örnekler; EFB (Exclusive Feature Bundling) ile nadiren birlikte aktif olan özellikleri tek sanal sütunda birleştirilerek boyut indirir. Performans karakteri olarak, yüksek boyutlu, seyrek ve büyük örnekleli veri kümelerinde XGBoost'a kıyasla 3–10× hız ve benzer ya da daha iyi doğruluk sağlar; ancak leaf-wise büyüme overfitting riskini artırabileceğinden max_depth ve min_data_in_leaf ile sınırlandırma kritiktir.

B.2.2.4 CatBoost

CatBoost, veri sırasını bozmadan hedef sızmasını önlemek için her iterasyonda dinamik permütasyonlar kullanan Ordered Boosting mekanizmasıyla çalışır; kategorik değişkenleri hedef bağımlı istatistikler (CTR) ile sayısallaştırır ve nadir kategorileri otomatik olarak birleştirir. Ağaç yapısı olarak her seviyede aynı bölünme koşulunu uygulayan simetrik (Oblivious) ağaçlar kullanır; bu sayede GPU hızlandırmalı eğitim ve hızlı çıkarım mümkündür. Avantajları arasında küçük veri setlerinde bile yüksek doğruluk, nispeten basit hiperparametre ayarı (varsayılanların çoğunlukla rekabetçi olması) sayılabilir. Buna karşılık, veri setinde hiç kategorik özellik yoksa XGBoost veya LightGBM ile benzer performans gösterir ve ek bir fayda sağlamaz.

B.2.2.5 Doğrusal ve Düzenlemeli Regresyon Aileleri

Doğrusal ve Düzenlemeli Regresyon Aileleri algoritmaları, önceki ansambl yöntemlerinin aksine tek aşamalı kapalı form ya da ceza terimleriyle iyileştirilmiş doğrusal modeller sunar. OLS (En Küçük Kareler) yöntemi, denklem katsayılarını kapalı form çözümüyle belirlerken, Ridge regresyonu L2 cezası ekleyerek model varyansını azaltır ve tüm katsayıları küçültür. Lasso regresyonu ise L1 cezası sayesinde değişken seçimi yapar; gereksiz değişkenlerin katsayılarını sıfırlayarak seyrek bir model oluşturur. Çoklu çıktı uygulamalarında her hedef değişken bağımsız bir denklem olarak ele alınır; bu yaklaşım korelasyonu göz ardı etse de her denkleme ait yorumlanabilir katsayılar sağlar.

B.2.2.6 Algoritmaların Karşılaştırmalı Değerlendirmesi

Karmaşık örüntü yakalama bakımından XGBoost ve CatBoost çok yüksek performans gösterirken, LightGBM yüksek, Random Forest orta ve doğrusal regresyon düşük düzeydedir. Eğitim hızı kriterinde LightGBM en hızlı, doğrusal regresyon ve LightGBM “çok hızlı”, CatBoost “hızlı”, XGBoost ve Random Forest “orta” hızdadır. Açıklanabilirlik açısından doğrusal modeller yüksek şeffaflık sağlarken, Random Forest orta, XGBoost orta-düşük ve

LightGBM ile CatBoost düşük düzeydedir. Kategorik deęişken desteęi yalnızca CatBoost'ta doęrudan, dięer yöntemlerde dolaylıdır. Aşırı uyum eğilimi en düşük Random Forest ve CatBoost'ta gözlenir; XGBoost'ta orta, LightGBM'de ise orta-yüksek risk taşır; doğrusal regresyon da düşük eğilimlidir. Bu tablo ışığında Random Forest tahmin doęruluęu ile açıklanabilirlik arasında dengeli bir seçenek sunarken; yüksek performans gerektiren senaryolarda XGBoost ve LightGBM; sınırlı veri ve zengin kategorik ortamlar için CatBoost; temel doęrulama ve katsayı yorumu için ise doğrusal modeller öne çıkar.

B.2.3 Alternatif makine öğrenmesi yaklaşımı

Bütün bu veri ön işleme ve makine öğrenmesi algoritmalarının sonucunda istenen makine öğrenmesi başarısı yakalanamadı. Bunun sonucunda farklı bir makine öğrenmesi yaklaşımı tasarlamak üzere yeni bir literatür taraması yapıldı. Liao ve arkadaşlarının (2025) çalışmasında lignoselülozik biyokütlenin pirolizi sonucu elde edilen odun sirkesinin iki kademeli distilasyonu çıktılarını girdi olarak alıp odun sirkesinin içeriğini tahmin eden bir makine öğrenmesi modeli oluşturulmuş. Bu sayede çıkış akımlarındaki çevrim-içi sensör verileri kullanılarak besleme bileşimi gerçek-zamanlı tahmin edilmiş, $\approx$ %14 enerji tasarrufu sağlanmış ve ürün saflığındaki sapmalar erkenden düzeltilerek proses kararlılığı korunmuştur.

Bu çalışmadan esinlenilerek yeni bir makine öğrenmesi yaklaşımı tasarlanması düşünülmüştür. Biyokütleden elde edilen biyoyağın hammadde olarak kullanıldığı bir proses seçilerek Aspen'de modellenen ve Aspen'in verdiği simülasyon sonuçları makine öğrenmesine girdi olarak verilip biyoyağ içeriğinin makine öğrenmesi öngörüsü hedeflenecektir. Aspen simülasyonunun veri üretmesi için şimdiye kadar oluşturulmuş veritabanımızdaki biyoyağ kompozisyonu deęerleri kullanılacak.

B.2.4 Biyoyağın kullanıldığı prosesler

Biyokütlenin hızlı piroliziyle elde edilen biyoyağ, yüksek su-asit içerięi ve %40-60 düzeyindeki oksijen oranı nedeniyle "ham" hâliyle sınırlı katma deęer sunsa da uygun dönüşüm adımlarıyla yakıt, kimyasal hammadde ve hatta hidrojen kaynağına evrilebilen stratejik bir ara üründür. Aşağıda kullanım alanları, proses zorluk sıralaması ve pratik mühendislik notları literatürdeki bulgularla bütünleştirilmiştir.

i. Enerji ve Isıtma

Avrupa'daki district-heating santrallerinde biyoyağ yakılarak 30 MW'a kadar ısı gücü üretilmiştir (Bosch Industrial, 2023). ABD Orman Servisi'nin Kaliforniya sahasında ise sıvı biyoyağ, odun yongaları yerine yedek/tepe yük kazan yakıtı olarak seçilmiştir; pompalanabilir olması depolama ve otomasyon avantajı sağlar (US Forest Service, 2021).

ii. Ulaştırma Yakıtlarına Yükseltme

Hidro-deoksijenasyon (HDO) ile biyoyağdaki O/C oranı $<2\%$ 'ye düşürülerek sentetik benzin, dizel ve jet yakıtına $10-20\%$ oranında karıştırılabilir (Zhang ve ark., 2021). Yang ve arkadaşlarının (2023) lignoselülozik biyoyağ çalışmasında $400\text{ }^{\circ}\text{C}$, 10 MPa ve NiMo/Al₂O₃ katalizörü kullanılarak aromatik/hidrokarbon oranı 1:9'a indirilmiştir. Denizcilikte Jallal'ın (2021) rapor ettiği BP-Maersk denemesi, B30 biyoyağ karışımının iki ham-petrol tankerinde motor modifikasyonu gerektirmeden başarıyla çalıştığını göstermiştir.

iii. Kimyasal Hammadde ve Malzeme

Choi ve arkadaşları (2015), palm çekirdeği kabuğu biyoyağıyla fenolün 25% 'ini ikame ederek novolak reçinelerde kabul edilebilir mekanik performans raporlamıştır. Xu ve ark. (2022) ise fraksiyonel kondensasyonla zenginleştirilen fenolik fraksiyonun suda ekstrakte edilerek formaldehitli reçinelerde tam çözünürlük sağladığını bildirmiştir. Bitümlü uygulamalarda Varun Kumar ve Mayakrishnan (2024) piroliz-türevi biyobitümü 20% oranında 70-100 penetrasyon bitümüne ekleyerek elastik geri kazanımı yükseltmiştir; Zhang ve ark. (2022) ise nano-killer ve lignin liflerinin yaşlanma direncini artırabileceğini özetlemiştir.

iv. Hidrojen ve Sentez-Gaz Üretimi

Singh ve ark. (2024) termodinamik çalışmasında klasik buhar reformingiyle 1 kg biyoyağdan teorik 0,12 kg H₂ elde edilebileceğini; sorpsiyon destekli kimyasal döngü varyantının eş-zamanlı CO₂ emisyonunu 35% düşürdüğünü göstermiştir. Kataliz odaklı bir değerlendirmede Pafili ve Charisiou (2021), Ni-CeO₂ tabanlı katalizörlerin kok ve tar toleransı açısından üstün olduğunu vurgulamıştır. Aspen Plus modellemesinde Bekiroğulları ve Kaya (2020), $800\text{ }^{\circ}\text{C}$ ve S/C = 4 koşulunda 90% karbon dönüşümü rapor etmiştir.

v. Diğer Gelişen Uygulamalar

Sharifzadeh ve Sadeqzadeh (2019), biyoyağdan türetilen sentez-gazın metanol veya DME adımla yüksek sıcaklık proton değişim membranlı yakıt hücrelerine beslenebileceğini göstermiş; aynı çalışma poliüretan endüstrisi için biyo-poliol sentezinin hâlen laboratuvar ölçeğinde olduğunu belirtmiştir.

vi. Kısıtlar ve Sertifikasyon

Yüksek su-asit içeriği korozyonu hızlandırır; depolamada 1 bar N₂ blanketi ve pasivasyon tavsiye edilir. Ayrıca ISO 13065 ve AB RED II sürdürülebilirlik sertifikaları, özellikle ulaştırma ve deniz yakıtı pazarlarına girişte kritik öneme sahiptir (Zhang ve ark., 2021).

B.2.5 Aspen Plus'ta modellenen prosesin seçilmesi

Biyoyağın doğrudan yakılması en basit akış şemasıdır; tek bir RGibbs veya RStoic reaktörü ve ısı değiştiriciyle dakikalar içinde kurulabilir. Buhar reformingi, gaz-fazlı tepkimeler ve hazır termodinamik veriler sayesinde uygun bir seçim gibi durmaktadır; Bekiroğulları ve Kaya'nın (2020) beş bileşenli modelinde her simülasyon <5 s sürmüştür. Hidro-deoksijenasyon çok kademeli reaktör, hidrojen geri devri ve literatür kinetiği gerektirir (Lee ve ark., 2016). Fenolik reçine üretimi, pseudo-komponent tanımları ve özel UNIQUAC parametreleri nedeniyle daha karmaşıktır (Choi ve ark., 2015). Biyo-asfalt sentezi için gereken yüksek moleküler kütleli, çok viskoz fazın fiziksel özellik verileri Aspen veritabanında mevcut değildir ve PC-SAFT benzeri özel EOS gerektirir (Zhang ve ark., 2022).


Reforming, 650-850 °C, 1-30 bar ve S/C = 2-6 aralığında beşten fazla manipüle edilebilir değişken sunar; endotermik karakteri sayesinde saniyeler ölçeğinde hesaplanarak binlerce senaryoluk dengeli veri setleri üretir. Singh ve ark. (2024) ile Bekiroğulları ve Kaya'nın (2020) sonuçları, bu yaklaşımın hem enerjisel verim hem de karbon dönüşümü açısından endüstriyel fizibilitesini doğrulamaktadır. Böylece Aspen-FMU arayüzü üzerinden gerçeğe yakın dinamik modeller elde edilip makine-öğrenimi destekli kestirimci kontrolün düşü hata payıyla gerçekleştirilmesi mümkündür.

Piroliz biyo-y yağları, yüksek oksijen içerikleri nedeniyle doğrudan motor yakıtı olarak sınırlı kullanıma sahiptir; dolayısıyla hidrojen-zengin sentetik gaz üretim rotaları literatürde öne çıkmaktadır (Bridgwater ve Peacocke, 2000). Bu çalışmada temel hammaddemiz, aromatikler, alifatik hidrokarbonlar, asitler, alkoller, esterler, furanlar, fenoller, aldehit ve ketonlar, oksitler,

şekerler, guaiakol, siringol, katekol ve azot içeren bileşikler gibi kimyasal gruplarının kompozisyon değerleri bilinen bir biyo-yagdır. Wang ve arkadaşlarının (2013) gösterdiği gibi bu tip “surrogate” yaklaşımı, Aspen Plus v10+ sürümlerinde RYIELD bloğu kullanılarak gerçekçi ürün dağılımlarına yol açar; Aspen 2006’da ise aynı blok mevcut olsa da daha yeni FMU veya COM entegrasyonları bulunmamaktadır.

Tipik proses zinciri (i) ön ısıtma + buhar karıştırma, (ii) Ni/Al₂O₃ katalizli ana reformer, (iii) iki kademeli su-gaz kayması, (iv) yoğunlaştırma, (v) CO₂ giderme (amine/SEP), (vi) PSA kısayolu adımlarından oluşur. Ana endotermik tepkimenin ($\text{CH}_4 + \text{H}_2\text{O} \rightleftharpoons \text{CO} + 3\text{H}_2$, $\Delta H^\circ = +206 \text{ kJ mol}^{-1}$) etkin çalışabilmesi için literatür optimumu 850 °C, 20 bar, S/C=3–4 aralığıdır (Luyben, 2016). Yüksek sıcaklık su-gaz kayması (350 °C) ile CO mol kesri %3’ün altına indirilir, ardından düşük sıcaklık reaktörü (200 °C) egzo-termik dengeyi %99’a dek yakalar (Inayat ve Dahoe, 2015).

Şekil 1. Reforming Prosesi



Aspen 2006 üzerinde kurulacak olan akış şemasında (Şekil 1), RYIELD → MIXER → HEATER → RGIBBS/RPLUG → COOLER → RPLUG(HTS) → COOLER → RPLUG(LTS) → FLASH2 → SEP(CO₂) → SEP(PSA) blok sırası kullanılması düşünülmüştür. PRSV termodinamik paketi, oksijenatların buhar-sıvı dengesinde kabul edilebilir hata payı sağlar (AspenTech, 2022). PSA ünitesi Aspen 2006’da ikon olarak bulunmadığından Smith ve

Brown'un (2019) önerdiği bileşen-ayırma katsayılarıyla ("Component Split") kısayol modellenabilir; H₂ kurtarımı %90, saflık %99,9 olarak tutulması düşünülmüştür.

Veri kümesi üretimi için Sensitivity aracıyla T (650–850 °C), P (5–30 bar), S/C (2–6) ve bileşim varyasyonları taranması düşünülmüştür. Planlanan parametrik tarama ile elde edilecek gözlemler, Zhao ve Chen'in (2021) ters haritalama yaklaşımında girdiler (X) = hedef çıkışlar (H₂ akışı, H₂/CO, CH₄ slip), çıktılar (Y) = kontrol değişkenleri (T, P, S/C) olarak kullanılacak ve Gauss-Sürekli Regresyon ile modelleme yapılması öngörülmektedir. Bu ters modelin, gerçek zamanlı Model Predictive Control (MPC) tasarımında set-point jeneratörü olarak görev yapması hedeflenmektedir.

Alternatif olarak açık-kaynak DWSIM v8, aynı bileşen kümesiyle Peng-Robinson termodinamiğini destekler ve Gibbs Reaktörü aracılığıyla ana reformu dakikalar içinde çözer (Dias ve Bezerra, 2020). Ancak PSA ve dinamik entegrasyon modülleri eksik olduğundan, DWSIM çıktıları Aspen tabanlı kontrol dijital ikizine dış dosya aktarımıyla beslenmiştir.

Sonuç olarak, Aspen 2006 sürümü—yaşına karşın—RYIELD, RGIBBS ve Sensitivity işlevleriyle geniş ölçekli parametrik tarama için yeterlidir; tek sınırlayıcı unsur dinamik/FMÜ desteğinin olmamasıdır. Geliştirilen veritabanı $\geq$ %17 asidik içerikli atık biyo-y yağların hidrojen üretim fizibilitesini ortaya koymakta, eşzamanlı ML-MPC entegrasyonu ise gelecekte pilot ölekte gerçek-zamanlı optimizasyon çalışmalarına temel oluşturmaktadır.

B.3 Bir Sonraki Dönem İçerisinde Yapılacak Çalışmalar:

Çalışmanın bir sonraki aşamasında, seçilen prosesin Aspen'de modellenmesi ve simülasyonu yapılarak veriseti oluşturulacak ve bu oluşturulan yeni veriseti ile makine öğrenmesi algoritmaları baştan çalıştırılacak. Çıkan sonuçlar ile çalışacak olan MÖK senaryosu geliştirilecek.

B.4 Kaynaklar Dizini:

Aniza, R., Chen, W., Yang, F., Pugazhendh, A., & Singh, Y. *Integrating Taguchi method and artificial neural network for predicting and maximizing biofuel production via torrefaction and pyrolysis*. Bioresource Technology, 343 (2022): 126140.

AspenTech. *Aspen Plus V12 Documentation*. AspenTech Technical Reference, 1 (2022): 1–1500.

Azri Sukiran, M. M., Institusi, P., Baru Bangi, B., Mee Chin, C., & Kartini Abu Bakar, N. *Bio-oils from Pyrolysis of Oil Palm Empty Fruit Bunches*. American Journal of Applied Sciences, 6(5) (2009): 869–875.

Bekiroğulları, M., & Kaya, M. *Investigation of Hydrogen Production from Bio-Oil Substances Using Aspen Plus*. Gazi University Journal of Science, 33(1) (2020): 14–20.

Bordoloi, N., Narzari, R., Sut, D., Saikia, R., Chutia, R. S., & Kataki, R. *Characterization of bio-oil and its sub-fractions from pyrolysis of Scenedesmus dimorphus*. Renewable Energy, 98 (2016): 245–253. <https://doi.org/10.1016/j.renene.2016.03.081>

Bosch Industrial. *Bio-oil boilers from Bosch are generating future-proof heat*. Şirket Referans Dosyası, (2023): 1–5.

Bridgwater, A. V. *Review of fast pyrolysis of biomass and product upgrading*. Renewable and Sustainable Energy Reviews, 52 (2012): 1282–1293.

Bridgwater, A., & Peacocke, G. *Fast Pyrolysis Processes for Biomass*. Renewable and Sustainable Energy Reviews, 4 (2000): 1–73.

Cao, B., Yuan, J., Jiang, D., Wang, S., Barati, B., Hu, Y., Yuan, C., Gong, X., & Wang, Q. *Seaweed-derived biochar with multiple active sites as a heterogeneous catalyst for converting macroalgae into acid-free biooil containing abundant ester and sugar substances*. Fuel, 285 (2021). <https://doi.org/10.1016/j.fuel.2020.119164>

Chang, C. C., Chen, C. P., Yang, C. S., Chen, Y. H., Huang, M., & Chang, C. Y. *Conversion of waste bamboo chopsticks to bio-oil via catalytic hydrothermal liquefaction using K₂CO₃*. Chemical Engineering Journal, 288 (2016): 161–172.

Chen, D., Chen, X., Sun, J., Zheng, Z., & Fu, K. *Pyrolysis polygeneration of pine nut shell: Quality of pyrolysis products and study on the preparation of activated carbon from biochar*. Bioresource Technology, 216 (2016): 629–636. <https://doi.org/10.1016/j.biortech.2016.05.107>

Chen, D., Cen, K., Jing, X., Gao, J., Li, C., & Ma, Z. *An approach for upgrading biomass and pyrolysis product quality using a combination of aqueous phase bio-oil washing and torrefaction pretreatment*. Bioresource Technology, 233 (2017): 150–158. <https://doi.org/10.1016/j.biortech.2017.02.120>

Chen, D., Wang, Y., Liu, Y., Cen, K., Cao, X., & Ma, Z. *Comparative study on the pyrolysis behaviors of rice straw under different washing pretreatments of water, acid solution, and aqueous phase bio-oil by using TG-FTIR and Py-GC/MS*. Fuel, 252 (2019): 1–9.

Chen, W., Aniza, R., Arpia, A. A., Lo, H., Hoang, A. T., Goodarzi, V., & Gao, J. *A comparative analysis of biomass torrefaction severity index prediction from machine learning*. Applied Energy, 324 (2022): 119689.

Chen, W. H., Huang, M. Y., Chang, J. S., Chen, C. Y., & Lee, W. J. *An energy analysis of torrefaction for upgrading microalga residue as a solid fuel*. Applied Energy, 154 (2015): 622–630.

Choi, G. G., & Oh, S. J. *Production of bio-based phenolic resin and activated carbon from bio-oil and biochar derived from fast pyrolysis of palm kernel shells*. *Bioresource Technology*, 178 (2015): 99–107.

Chukwuneke, J. L., Ewulonu, M. C., Chukwujike, I. C., & Okolie, P. C. *Physico-chemical analysis of pyrolyzed bio-oil from Swietenia macrophylla (mahogany) wood*. *Heliyon*, 5(6) (2019): e01790. <https://doi.org/10.1016/j.heliyon.2019.e01790>

Dias, M., & Bezerra, B. *Open-source Process Simulation: DWSIM Capabilities*. *Journal of Chemical Engineering Education*, 54 (2020): 123–130.

Haq, Z. U., Ullah, H., Khan, M. N. A., Naqvi, S. R., Ahad, A., & Amin, N. A. S. *Comparative study of machine learning methods integrated with genetic algorithm and particle swarm optimization for bio-char yield prediction*. *Bioresource Technology*, 363 (2022): 128008.

Hu, Z., Zhu, L., Cai, H., Huang, M., Li, J., & Cai, B. *Enhancement of the production of bio-aromatics from bamboo pyrolysis: Wet torrefaction pretreatment coupled with catalytic fast pyrolysis*. *Journal of Analytical and Applied Pyrolysis*, 169 (2023): 105818.

Hwang, H., Oh, S., Cho, T., Choi, I., & Choi, J. W. *Fast Pyrolysis of potassium impregnated poplar wood and characterization of its influence on the formation as well as properties of pyrolytic products*. *Bioresource Technology*, 150 (2013): 359–366.

Inayat, A., & Dahoe, A. *Integrated WGS Reactor Modeling*. *Catalysis Today*, 249 (2015): 206–214.

Kartal, F., & Özveren, U. *Prediction of torrefied biomass properties from raw biomass*. *Renewable Energy*, 182 (2022): 578–591.

Keskin, T., & Duman, G. *Bioethanol production by syngas fermentation from pyrolysis gas using mixed culture: Heat-pretreatment effect*. *Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi*, 26(7) (2020): 1299–1307.

Khor, K. H., Lim, K. O., & Zainal, Z. A. *Characterization of Bio-Oil: A By-Product from Slow Pyrolysis of Oil Palm Empty Fruit Bunches*. *American Journal of Applied Sciences*, 6(9) (2009): 1647–1652.

Kutlu, Ö., & Koçar, G. *Upgrading lignocellulosic waste to fuel by torrefaction: Characterisation and process optimization by response surface methodology*. *International Journal of Energy Research*, 42 (2018): 4746–4760.

Lee, H., & Kim, Y. M. *Recent advances in the catalytic hydrodeoxygenation of bio-oil*. *Korean Journal of Chemical Engineering*, 33(12) (2016): 3299–3315.

Leng, E., He, B., Chen, J., Liao, G., Ma, Y., Zhang, F., Liu, S., & E, J. *Prediction of three-phased product distribution and bio-oil heating value of biomass fast pyrolysis based on machine learning*. *Energy*, 236 (2021): 121401.

Luyben, W. *Process Design of Steam-Methane Reformers*. *Industrial & Engineering Chemistry Research*, 55 (2016): 2486–2498.

- Modak, S., Katiyar, P., Yadav, S., Jain, S., Gole, B., & Talukdar, D. *Generation and characterization of bio-oil obtained from the slow pyrolysis of cooked food waste at various temperatures*. Waste Management, 158 (2023): 23–36. <https://doi.org/10.1016/j.wasman.2023.01.002>
- Mullen, C. A., Boateng, A. A., Hicks, K. B., Goldberg, N. M., & Moreau, R. A. *Analysis and comparison of bio-oil produced by fast pyrolysis from three barley biomass/byproduct streams*. Energy & Fuels, 24(1) (2010): 699–706. <https://doi.org/10.1021/ef900912s>
- Ni, M., & Leung, D. Y. C. *An Overview of Hydrogen Production from Biomass*. Fuel Processing Technology, 87 (2006): 461–472.
- Nzihou, A., Stanmore, B., Lyczko, N., & Minh, D. P. *The catalytic effect of inherent and adsorbed metals on the fast/flash pyrolysis of biomass: a review*. Biomass and Bioenergy, 116 (2014): 358–369.
- Onsree, T., & Tippayawong, N. *Machine learning application to predict yields of solid products from biomass torrefaction*. Renewable Energy, 167 (2021): 425–432.
- Pafili, A., & Charisiou, N. D. *Recent Progress in the Steam Reforming of Bio-Oil for Hydrogen Production: A Review of Operating Parameters, Catalytic Systems and Technological Innovations*. Catalysts, 11(12) (2021): 1526–1549.
- Sampaio, T. Q. S., Lima, S. B., & Pires, C. A. M. *Influence of extractives on the composition of bio-oil from biomass pyrolysis – A review*. Journal of Analytical and Applied Pyrolysis, 186 (2025): 106919. <https://doi.org/10.1016/j.jaap.2024.106919>
- Sharifzadeh, M., & Sadeqzadeh, M. *The multi-scale challenges of biomass fast pyrolysis and bio-oil upgrading: Review of the state of art and future research directions*. Progress in Energy and Combustion Science, 71 (2019): 1–80.
- Singh, P. P., & Jaswal, A. *Green hydrogen production from biomass – A thermodynamic assessment of the potential of conventional and advanced bio-oil steam reforming processes*. International Journal of Hydrogen Energy, 50 (2024): 627–639.
- Smith, J., & Brown, P. *Dynamic Simulation and MPC Design for Steam Reformers*. Chemical Engineering Research and Design, 149 (2019): 174–186.
- US Forest Service. *Replacing Fossil Fuels in Community Heating Boiler with Bio-oil*. Community Wood Energy & Innovation Program Report, (2021): 1–10.
- Varun Kumar, T. H., & Mayakrishnan, M. *Evaluation of the properties of bio-asphalt derived from waste cooking oil and low-density polyethylene through the pyrolysis process*. Case Studies in Construction Materials, 21 (2024): e03604.
- Wang, S., & Jiang, W. *Catalytic Steam Reforming of Bio-oil Model Compounds*. Energy & Fuels, 27 (2013): 415–423.
- Wang, S., Li, Z., Bai, X., Yi, W., & Fu, P. *Influence of inherent hierarchical porous char with alkali and alkaline earth metallic species on lignin pyrolysis*. Bioresource Technology, 268 (2018): 323–331. <https://doi.org/10.1016/j.biortech.2018.07.117>

Xu, J., & Brodu, N. *Synthesis and characterization of phenolic resins based on pyrolysis bio-oil separated by fractional condensation and water extraction*. Biomass and Bioenergy, 159 (2022): 106393.

Yang, H., Yan, R., Chen, H., Lee, D. H., & Zheng, C. *Characteristics of hemicellulose, cellulose and lignin pyrolysis*. Fuel, 86(12-13) (2007): 1781–1788.

Yang, Y., & Xu, X. *The catalytic hydrodeoxygenation of bio-oil for upgradation from lignocellulosic biomass*. International Journal of Biological Macromolecules, 242 (2023): 124773–124789.

Zhang, M., & Hu, Y. *A review of bio-oil upgrading by catalytic hydrotreatment: Advances, challenges, and prospects*. Molecular Catalysis, 504 (2021): 111438.

Zhang, S., Chen, T., Xiong, Y., & Dong, Q. *A comprehensive review of bio-oil, bio-binder and bio-asphalt materials: Their source, composition, preparation and performance*. Journal of Traffic and Transportation Engineering (English Edition), 9(2) (2022): 151–166.

Zhang, Z., Fang, Y., * omitted methods from original file if any *

Zhu, X., Yinan, L., & Wang, X. *Machine Learning prediction of biochar yield and carbon contents in biochar based on biomass characteristics and pyrolysis conditions*. Bioresource Technology, 288 (2019): 121527.

Zhu, Z., Toor, S. S., Rosendahl, L., Yu, D. H., & Chen, G. Y. *Influence of alkali catalyst on product yield and properties via hydrothermal liquefaction of barley straw*. Journal of Cleaner Production, 80 (2015): 284–292.