



EGE ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ



DOKTORA TEZ İZLEME RAPORU-5

A. TEZ PROJESİNE İLİŞKİN GENEL BİLGİLER

A.1 Tezin Adı: Biyokütleden Elde Edilen Biyoyağ Kompozisyonunun Makine Öğrenmesi ile Tahmini ve Model Öngörülü Kontrol Tabanlı Süreç Optimizasyonu

A.2 Tez Danışmanı ve Yürütücüsü

- a. Tez Danışmanı:** Dr. Öğretim Üyesi Özben KUTLU
- b. Tez İzleme Komitesi:** Prof. Dr. Harun Kemal ÖZTÜRK,
Doç. Dr. Hasan SARPTAŞ
- c. Tez Yürütücüsü:** Orhun UZDİYEM

A.3 Tezin Yürütüldüğü Anabilim Dalı: Güneş Enerjisi Enstitüsü -
Enerji Teknolojisi Bilim Dalı

A.4 Tezin Yürütülmesinde İş birliği Yapılacak Kurum ve Kuruluşlar: -

A.5 Tezin Başlangıç ve Bitiş Tarihi: 02/01/2024 - 02/01/2027

B. TEZİN PLANLANMASI VE YAPILAN ÇALIŞMALAR

B.1 Tezin Amacı:

Bu tez çalışmasında biyokütlenin yavaş pirolizi sırasında ortaya çıkan ürün biyoyağın değerlendirilerek katma değerli ürüne dönüştürülmesi üzerinde durulmuştur. Biyoyağ, petrol türevlerine alternatif olabilecek değerli hidrokarbonları içeren bir üründür. Ancak, biyokütlenin türüne ve proses koşullarına bağlı olarak biyoyağ içeriği de oldukça değişkenlik gösterir [Zhang et al, 2017]. Bu durum, biyoyağın işlenmesi ve değerlendirilmesi süreçlerini karmaşıktırılmaktadır. Çünkü biyoyağın işleneceği proses parametrelerinin belirlenmesinde temel etken biyoyağ kompozisyonudur. Ayrıca biyoyağ kalitesinin düşük olma ihtimali de uygulama alanını daraltmaktadır [Keskin and Duman, 2020]. Bu nedenlerle yükseltme reaksiyonları için pahalı proseslere ihtiyaç duyabilecek biyoyağın nasıl değerlendirileceğine

karar vermek zorlaşmaktadır.

Biyoyağ, değerli hidrokarbon içeriği ile gerek biyoyakıt gerek karbon nanomalzeme gerekse de karbon fiber gibi polimerlere dönüştürülebilen değerli bir ara üründür. Ancak kompozisyonunun kaynağa bağlı olarak farklılık göstermesi ve dolayısıyla da maliyetli yükseltgenme/indirgenme proseslerine ihtiyaç duyması sebebiyle ticari piroliz sistemlerinde verimli bir şekilde değerlendirilememektedir.

Bu çalışmanın temel amacı, biyokütleden elde edilen biyoyağın işlenmesi sonucu oluşan ürünün özelliklerin bakarak, girişte kullanılan biyoyağın içeriğini tahmin edebilen bir yapayzeka modeli geliştirmek ve bu tahminler doğrultusunda biyoyağın değerlendirildiği prosesin parametrelerinin belirlenmesine yardımcı olacak bir model öngörülü kontrol (MÖK) senaryosu geliştirmektir.


B.2 Dönem İçerisinde Yapılan Çalışmalar:

Bu dönem içerisinde yapılan çalışma, önceki tez izleme döneminde geliştirilen ters makine öğrenmesi modelinin süreç optimizasyonu ve model öngörülü kontrol yapısı içerisinde kullanılmasına odaklanmıştır. Önceki çalışmada, biyoyağ buhar reforming prosesi için reformer çıkışındaki singaz kompozisyonundan girişte kullanılan biyoyağın kimyasal kompozisyonunu tahmin eden bir derin öğrenme modeli geliştirilmişti. Bu dönemde ise bu model, tek başına bir tahmin aracı olarak değil, prosesin izlenmesi ve uygun çalışma koşullarının belirlenmesi için kullanılan bir soft-sensor bileşeni olarak ele alınmıştır.

Tablo 1. Geliştirilen yazılım dosyaları ve işlevleri

Dosya/modül	İşlev
`src/common.py`	Ortak kolon adları, veri yolu tanımları ve yardımcı fonksiyonlar
`src/inverse_predictor.py`	Ters makine öğrenmesi (machine learning - ML) modelini soft-sensor olarak çalıştıran tahmin arayüzü
`src/biooil_holdout_validation.py`	BiooilID bazlı eğitim/test ayrımı ve validasyon metrikleri
`src/surrogate_model.py`	İleri vekil model eğitimi ve performans değerlendirmesi
`src/optimization.py`	Amaç fonksiyonu ve statik optimizasyon hesaplamaları
`src/mpc_controller.py`	Basit MÖK döngüsü ve bozucu etki senaryosu
`run_case_studies.py`	Statik optimizasyon ve MÖK case-study çalıştırma dosyası

Çalışmanın temel amacı, ölçülen veya simülasyonla elde edilen singaz kompozisyonundan biyoyağ bileşimini tahmin etmek ve bu tahmini kullanarak hedeflenen H₂/CO oranına mümkün olduğunca yaklaşan, enerji açısından daha uygun reformer çalışma koşullarını belirleyen bir optimizasyon ve model öngörülü kontrol yapısı oluşturmaktır. Bu kapsamda reformer sıcaklığı, basınç ve buhar/karbon oranı karar değişkenleri olarak seçilmiş; biyoyağ kompozisyonu ise ters makine öğrenmesi modeli tarafından tahmin edilen sabit proses girdisi olarak değerlendirilmiştir.



Figür 1. Ters ML destekli optimizasyon ve MÖK genel sistem mimarisi

Bu dönemde yapılan çalışma üç ana aşamada yürütülmüştür. İlk aşamada, mevcut ters makine öğrenmesi modeli kullanıma hazır bir tahmin arayüzüne dönüştürülmüştür. İkinci aşamada, optimizasyon ve MÖK hesaplamalarında Cantera simülasyonlarını tekrar tekrar çalıştırmak yerine hızlı sonuç verebilecek ileri bir vekil model geliştirilmiştir. Son aşamada ise statik optimizasyon ve basit bir MÖK senaryosu oluşturularak sistemin farklı biyoyağ kompozisyonları ve bozucu etkiler altında nasıl davrandığı incelenmiştir.

Bu bölümde sırasıyla önceki çalışmanın bu döneme nasıl temel oluşturduğu, geliştirilen soft-sensor yapısı, ileri vekil model, optimizasyon problemi, statik optimizasyon sonuçları ve MÖK senaryosu açıklanacaktır. Çalışma sonunda elde edilen tablolar ve figürler, geliştirilen sistemin hem tahmin hem de kontrol/optimizasyon açısından uygulanabilirliğini göstermek amacıyla rapora eklenmiştir.

B.2.1 Ters makine öğrenmesi modelinin soft-sensör olarak kullanılması

Bu dönem yapılan çalışmanın ilk aşamasında, önceki dönemde geliştirilen standart MLP tabanlı ters makine öğrenmesi modeli proses optimizasyonu ve model öngörülü kontrol yapısında kullanılabilecek bir soft-sensor bileşeni haline getirilmiştir. Soft-sensor kavramı, doğrudan veya hızlı biçimde ölçülmesi zor olan bir proses değişkeninin, ölçülebilen diğer değişkenler yardımıyla hesaplamalı olarak tahmin edilmesini ifade etmektedir. Bu çalışmada doğrudan ölçülmesi daha zor, pahalı ve zaman alıcı olan biyoyağ kompozisyonu, reformer çıkışında ölçülebilen singaz kompozisyonu ve bilinen işletme koşulları kullanılarak tahmin edilmektedir.

Biyoyağın ayrıntılı kimyasal karakterizasyonu için GC-MS, FTIR ve benzeri analiz yöntemlerine ihtiyaç duyulmaktadır. Bu analizler laboratuvar koşullarında yapılmakta, numune hazırlama ve analiz süreci zaman alabilmektedir. Buna karşılık reformer çıkışındaki H₂, CO, CO₂, CH₄ ve H₂O gibi gaz bileşenleri proses hattında daha hızlı izlenebilir niteliktedir. Bu nedenle, singaz kompozisyonundan biyoyağ kompozisyonunu tahmin eden ters model, prosesin anlık hammadde karakteristiğini izlemek için uygun bir soft-sensor yapısı sağlamaktadır.

Geliştirilen soft-sensor yapısında model girişleri reformer sıcaklığı, reformer basıncı, buhar/karbon oranı, H₂ mol yüzdesi, CO mol yüzdesi, CO₂ mol yüzdesi, CH₄ mol yüzdesi ve H₂O mol yüzdesidir. Model çıktıları ise biyoyağ kompozisyonunu temsil eden altı bileşen grubudur: aromatikler, asitler, alkoller, furanlar, fenoller ve aldehit-ketonlar. Bu yapı, önceki dönemde eğitilen standart MLP modelinin doğrudan kullanılmasına olanak tanımaktadır.

Bu dönemde mevcut MLP modeli için ayrı bir tahmin arayüzü oluşturulmuştur. Bu arayüz, kaydedilmiş model dosyasını ve ölçeklendirme parametrelerini yüklemekte, verilen singaz ve proses koşullarını modelin beklediği giriş formatına dönüştürmekte ve biyoyağ kompozisyonu tahminini yüzde bileşim olarak üretmektedir. Böylece model, yalnızca eğitim scriptleri içinde çalışan bir yapı olmaktan çıkarılmış ve optimizasyon/MÖK algoritmaları tarafından çağrılabilir bir modül haline getirilmiştir.

Modelin çalışması sırasında öncelikle giriş değişkenleri eğitim aşamasında kullanılan ölçeklendirici ile standartlaştırılmaktadır. Daha sonra standart MLP modeli bu ölçeklendirilmiş girdiler üzerinden altı bileşenli biyoyağ kompozisyonunu tahmin etmektedir. Model çıktıları tekrar gerçek yüzde ölçeğine dönüştürülmekte ve negatif tahminler fiziksel anlam taşımadığı için sıfır altına düşmeyecek şekilde sınırlandırılmaktadır. Gerekli durumlarda çıktı bileşenleri toplamı %100 olacak şekilde normalize edilmektedir. Bu işlem, MÖK ve optimizasyon

aşamalarında fiziksel olarak anlamlı bir biyoyağ kompozisyonunun kullanılmasını sağlamaktadır.


Reformerden elde edilen singaz kompozisyonu ve bilinen proses koşulları ters ML modeline girdi olarak verilmekte, model biyoyağ kompozisyonunu tahmin etmekte ve bu tahmin ileri model ile optimizasyon bloğuna aktarılmaktadır. Böylece proses çıkışından hammadde kompozisyonu kestirilmekte ve bu kestirim kullanılarak bir sonraki kontrol hamlesi hesaplanmaktadır.

Bu yapının tez çalışması açısından önemi, biyoyağ kompozisyonunu yalnızca deneysel analizle belirlenen statik bir bilgi olmaktan çıkarıp, proses sırasında izlenebilir bir değişken haline getirmesidir. Reformer çıkışındaki singaz kompozisyonunda meydana gelen değişimler, ters model aracılığıyla biyoyağ kompozisyonundaki olası değişimlere dönüştürülebilmektedir. Bu durum, özellikle farklı kaynaklardan gelen biyoyağların değişken kompozisyonlara sahip olduğu sürekli proseslerde hammadde kalite kontrolü ve proses optimizasyonu açısından avantaj sağlamaktadır.

Bu dönem oluşturulan soft-sensor modülü, sonraki alt bölümlerde anlatılan ileri vekil model, statik optimizasyon ve MÖK senaryosunun temel giriş bileşenlerinden biridir. Model doğrudan proses koşullarını belirlememekte, bunun yerine optimizasyon sistemine biyoyağ kompozisyonu tahmini sağlamaktadır. Optimizasyon sistemi ise bu tahmini kullanarak hedef H₂/CO oranına yaklaşan uygun T, P ve S/C değerlerini hesaplamaktadır.


B.2.2 İleri vekil modelin geliştirilmesi

Bu dönemde, ters makine öğrenmesi modelini optimizasyon ve MÖK yapısında kullanabilmek için ters tahmin yapısını tamamlayan bir ileri vekil model geliştirilmiştir. Ters model, reformer çalışma koşulları ve sentez gazı bileşiminden biyoyağ kompozisyonunu tahmin etmektedir. Optimizasyon algoritmasının aday sıcaklık, basınç ve buhar/karbon oranı değerlerini hızlı biçimde değerlendirebilmesi için ise belirli bir biyoyağ kompozisyonu ve proses koşulu altında oluşacak sentez gazı bileşimini öngören ileri modele ihtiyaç duyulmuştur.



Figür 2. İleri vekil modelin giriş-çıkış yapısı ve optimizasyon bloğu ile ilişkisi

İleri modelde giriş değişkenleri biyoyağı temsil eden altı bileşen grubu ile reformer sıcaklığı, reformer basıncı ve buhar/karbon oranı olarak tanımlanmıştır. Model çıktıları H₂, CO, CO₂, CH₄ ve H₂O mol yüzdeleri ile H₂/CO oranıdır. Böylece model, her aday kontrol hareketi için Cantera simülasyonu çalıştırmadan hızlı bir performans tahmini üretebilecek hesaplama bloğu olarak kullanılmıştır.



Figür 3. İleri vekil model için gerçek ve tahmin edilen sentez gazı çıktılarının karşılaştırılması

Model, temizlenmiş Cantera veri seti üzerinde çok çıkışlı regresyon problemi olarak eğitilmiştir. Geliştirilen yazılım yapısında model eğitimi ve değerlendirme işlemleri `surrogate\_model.py` modülü altında toplanmıştır. Bu yapı veri setinin okunması, giriş-çıkış kolonlarının ayrılması, model eğitimi, test performansının hesaplanması ve eğitilmiş modelin optimizasyon modülüne aktarılması adımlarını içermektedir.

Model performansı sentez gazı bileşenleri ve H₂/CO oranı için ayrı ayrı değerlendirilmiştir. Ortalama R² değerinin 0.996, ortalama RMSE değerinin 0.268 ve ortalama MAE değerinin 0.125 seviyesinde bulunması, ileri vekil modelin Cantera tabanlı veri uzayını yüksek doğrulukla temsil edebildiğini göstermektedir. Bu nedenle bu model, bu dönem geliştirilen statik optimizasyon ve MÖK senaryolarında hızlı proses tahmincisi olarak kullanılmıştır.

B.2.3 Optimizasyon probleminin tanımlanması

Bu dönemde geliştirilen optimizasyon problemi, biyoyağ buhar reformlama sürecinde istenen H₂/CO oranına mümkün olduğunca yakın sentez gazı üretirken prosesin enerji/işletme maliyetini azaltmayı hedefleyecek şekilde tanımlanmıştır. Optimizasyon yapısında biyoyağ kompozisyonu sabit bir durum girdisi olarak ele alınmış, karar değişkenleri ise yalnızca doğrudan kontrol edilebilir proses değişkenleri olan reformer sıcaklığı, reformer basıncı ve buhar/karbon oranı ile sınırlandırılmıştır.

Tablo 2. Optimizasyon karar değişkenleri ve sınırları

Karar değişkeni	Alt sınır	Üst sınır	Birim
Reformer sıcaklığı	650	850	°C
Reformer basıncı	5	30	Bar
Buhar/karbon oranı	2	6	-

Amaç fonksiyonu iki ana hedefi birlikte içermektedir. Birinci hedef, sentez gazının H₂/CO oranını belirlenen hedef değere yaklaştırmaktır. İkinci hedef ise daha düşük enerji ve işletme maliyeti temsil eden çalışma koşullarını tercih etmektir. Bu nedenle sıcaklık, basınç ve buhar/karbon oranı için normalize edilmiş bir maliyet terimi tanımlanmış; sıcaklık maliyeti daha baskın, buhar/karbon oranı ve basınç maliyetleri ise daha düşük ağırlıklı olacak şekilde ele alınmıştır. Ayrıca hidrojen üretiminin çok düşük kalmasını ve CO₂ oluşumunun artmasını önlemek için ceza terimleri kullanılmıştır.

Tablo 3. Amaç fonksiyonu bileşenleri


Amaç fonksiyonu bileşeni	Rolü
H ₂ /CO hedef sapması	Sentez gazı oranını hedef değere yaklaştırır
Enerji/işletme maliyeti	Daha düşük sıcaklık, basınç ve buhar kullanımını teşvik eder
H ₂ alt sınır cezası	Hidrojen üretiminin yetersiz kalmasını engeller
CO ₂ üst sınır cezası	CO ₂ oluşumunun artmasını sınırlar
Kontrol hareketi cezası	MÖK senaryosunda ani kontrol değişimlerini azaltır

Optimizasyon algoritması, tanımlanan sınırlar içinde aday çalışma koşullarını değerlendiren ızgara tabanlı bir tarama yaklaşımı ile uygulanmıştır. Bu tercih, üç kontrol değişkenli problemde kararlı, hızlı ve yorumlanabilir sonuçlar üretmiştir. Her aday noktada ileri vekil model çalıştırılmış, elde edilen sentez gazı çıktıları amaç fonksiyonuna aktarılmış ve en düşük amaç fonksiyonu değerini veren çalışma koşulu seçilmiştir.

B.2.4 Statik optimizasyon çalışmaları

Tanımlanan optimizasyon yapısı öncelikle statik case-study senaryoları üzerinde test edilmiştir. Bu amaçla üç farklı biyoyağ tipi seçilmiştir: aromatik bakımından zengin, asit bakımından zengin ve daha dengeli kompozisyona sahip biyoyağ örnekleri. Her bir biyoyağ için başlangıç koşulu 750 °C reformer sıcaklığı, 15 bar basınç ve 4 buhar/karbon oranı olarak alınmıştır. Optimizasyon çalışmaları H₂/CO hedefinin 2.0 ve 2.5 olduğu iki farklı senaryo için yürütülmüştür.

Başlangıç koşullarında H₂/CO oranları yaklaşık 5.78-6.07 aralığında bulunmuştur. Optimizasyon sonrasında bu oranlar seçilen biyoyağ kompozisyonuna ve hedef değere bağlı olarak yaklaşık 2.52-2.82 aralığına düşürülmüştür. Bu sonuç, geliştirilen optimizasyon yapısının sentez gazı kompozisyonunu hedeflenen kimyasal kullanım aralığına yaklaştırdığını göstermektedir. Bununla birlikte H₂/CO = 2.0 hedefi, tanımlanan kontrol değişkeni sınırları ve mevcut veri uzayı içinde tam olarak yakalanamamıştır. Bu durum, hedef değer bazda bazı biyoyağ kompozisyonları için mevcut çalışma aralığında erişilebilir olmadığını göstermektedir.



Figür 4. Statik optimizasyon senaryolarında başlangıç ve optimize edilmiş H₂/CO oranlarının karşılaştırılması.

H₂/CO = 2.5 hedefinde, özellikle aromatik bakımından zengin ve dengeli biyoyağ örneklerinde hedefe daha yakın sonuçlar daha düşük enerji maliyetiyle elde edilmiştir. Asit bakımından zengin biyoyağ örneğinde ise model, hedefe yaklaşmak için yine yüksek sıcaklık ve düşük basınç koşulunu seçmiştir. Bu bulgu, biyoyağ kompozisyonunun optimum proses koşulları üzerinde doğrudan etkili olduğunu ve kompozisyon bilgisinin optimizasyon yapısına dahil edilmesinin gerekli olduğunu göstermektedir.


B.2.5 Model öngörülü kontrol senaryosunun geliştirilmesi

Statik optimizasyon çalışmasının ardından, geliştirilen soft-sensor ve ileri vekil model kullanılarak basit bir model öngörülü kontrol senaryosu oluşturulmuştur. Bu senaryoda amaç, biyoyağ kompozisyonu zamanla değiştiğinde sentez gazı H₂/CO oranını hedef değere yakın tutacak kontrol hareketlerini hesaplamaktır. MÖK yapısı, her zaman adımında mevcut ölçüm bilgisini kullanarak biyoyağ kompozisyonunu tahmin etmekte, ardından ileri vekil model yardımıyla yeni kontrol değişkenlerini belirlemektedir.

Tablo 4. MÖK senaryosunda kullanılan başlangıç koşulları

Parametre	Değer
Başlangıç biyoyağ tipi	Dengeli kompozisyon
Başlangıç BiooilID	60
Başlangıç sıcaklığı	750 °C
Başlangıç basıncı	15 bar
Başlangıç S/C oranı	4
H ₂ /CO hedefi	2.0
Bozucu etki zamanı	5. zaman adımı

Geliştirilen kapalı çevrim senaryoda ölçülen sentez gazı bileşimi ve mevcut proses koşulları ters ML soft-sensor modeline verilmiştir. Soft-sensor çıktısı olarak elde edilen biyoyağ kompozisyonu, ileri vekil modelin girişine aktarılmıştır. Optimizasyon modülü, sıcaklık, basınç ve buhar/karbon oranı adaylarını değerlendirerek bir sonraki zaman adımı için en uygun kontrol hareketini seçmiştir. Bu yaklaşımda her adımda yalnızca ilk kontrol hareketi uygulanmış ve sonraki adımda ölçüm/tahmin döngüsü tekrarlanmıştır.

**Figür 5.** Soft-sensor, ileri vekil model ve optimizasyon bloğundan oluşan MÖK kapalı çevrim yapısı

MÖK senaryosunda karar değişkenleri statik optimizasyonla aynı tutulmuştur. Ek olarak, kontrol hareketlerinin çok sert değişmesini önlemek için amaç fonksiyonuna hareket cezası eklenmiştir. Böylece algoritma yalnızca hedef H₂/CO oranına yaklaşmayı değil, aynı zamanda daha düzenli kontrol hareketleri üretmeyi de dikkate almıştır. Bu yapı, gerçek zamanlı uygulama için henüz deneysel bir kontrol sistemi değildir; ancak geliştirilen ML modellerinin

kapalı çevrim karar verme yapısında nasıl kullanılabileceğini gösteren bir hesaplamalı senaryodur.


B.2.6 MÖK senaryo bozucu etki analizi

MÖK senaryosu, dengeli biyoyağ kompozisyonu ile başlatılmış ve 10 zaman adımı boyunca çalıştırılmıştır. Başlangıç koşulunda sentez gazı H₂/CO oranı 5.907 olarak hesaplanmıştır. Kontrol algoritması ilk adımda sıcaklığı 850 °C, basıncı 5 bar ve buhar/karbon oranını 2 olarak seçmiş; bu kontrol hareketi sonrasında H₂/CO oranı yaklaşık 2.65 seviyesine düşmüştür. Bu değer H₂/CO = 2.0 hedefini tam olarak yakalamasa da başlangıç durumuna göre önemli bir iyileşme sağlamıştır.

Tablo 5. MÖK senaryosu özet sonuçları

Zaman adımı	Durum	Uygulanan T (°C)	Uygulanan P (bar)	Uygulanan S/C	Ölçülen H ₂ /CO	Sonraki tahmin H ₂ /CO
0	Başlangıç	750	15	4	5.907	2.639
1	Kontrol sonrası	850	5	2	2.647	2.639
5	Bozucu etki sonrası	850	5	2	2.671	2.670
9	Son durum	850	5	2	2.671	2.670

Senaryonun beşinci zaman adımında bozucu etki uygulanmıştır. Bu bozucu etki, biyoyağ kompozisyonunda asit içeriğinin artırılması, aromatik ve fenolik bileşenlerin azaltılması şeklinde tanımlanmıştır. Bozucu etki sonrasında sistemin H₂/CO oranı yaklaşık 2.67 seviyesine yerleşmiştir. Kontrol algoritması aynı çalışma koşullarını koruyarak sentez gazı oranını dar bir aralıkta tutmuştur. Bu sonuç, geliştirilen hesaplamalı MÖK yapısının kompozisyon değişimine rağmen sentez gazı oranını başlangıçtaki yüksek değerden hedef bölgeye yakın bir aralığa çekebildiğini göstermektedir.




Figür 6. MÖK zaman serisi, H2/CO oranı ve kontrol değişkenlerinin değişimi

Soft-sensor çıktıları bozucu etki sonrasında gerçek biyoyağ kompozisyonundaki yönelimi genel olarak takip etmiştir. Bununla birlikte bazı bileşenlerde, özellikle alkol ve aldehit-keton gruplarında farklar görülmüştür. Bu farklar, BiooilID bazlı validasyon sonuçlarıyla uyumludur ve kapalı çevrim uygulamada soft-sensor belirsizliğinin dikkate alınması gerektiğini göstermektedir.

B.2.7 Dönem içi çalışma sonuçları

Bu dönem çalışmasında önceki dönemde geliştirilen ters makine öğrenmesi modeli, optimizasyon ve MÖK yapısında kullanılabilecek bir soft-sensor bileşeni olarak konumlandırılmıştır. Bunun için modelin giriş-çıkış arayüzü tanımlanmış, biyoyağ kompozisyon tahminleri kontrol algoritmasına aktarılabilir hale getirilmiş ve modelin BiooilID bazlı genelleme davranışı ayrıca incelenmiştir.



Figür 7. TİK-5 döneminde geliştirilen soft-sensor, ileri vekil model, optimizasyon ve MÖK sisteminin nihai özet akışı

BiooilID bazlı validasyon, modelin bazı bileşen gruplarında güçlü genelleme performansı verdiğini, bazı bileşenlerde ise yeni biyoyağ kompozisyonlarına geçildiğinde belirsizliğin arttığını göstermiştir. Bu sonuç, sonraki çalışmalarda model belirsizliği, veri çeşitliliği ve kompozisyon temsili konularının geliştirilmesi gerektiğini ortaya koymuştur.

Bu dönemin ikinci ana çıktısı ileri vekil modeldir. Bu model, biyoyağ kompozisyonu ve proses koşullarından sentez gazı bileşimini yüksek doğrulukla tahmin etmiş ve ortalama $R^2 = 0.996$ performansına ulaşmıştır. Böylece optimizasyon ve MÖK algoritmalarının her aday çalışma koşulu için Cantera simülasyonu çalıştırmadan hızlı karar üretmesi mümkün hale gelmiştir.

Statik optimizasyon çalışmaları, üç farklı biyoyağ tipi için başlangıçta yaklaşık 5.8-6.1 aralığında bulunan H_2/CO oranının yaklaşık 2.5-2.8 aralığına indirilebildiğini göstermiştir. MÖK senaryosu ise kompozisyon bozucu etkisi altında H_2/CO oranının başlangıçtaki yüksek değerden hedef bölgeye yakın ve daha kararlı bir aralığa çekilebildiğini ortaya koymuştur. Bununla birlikte $H_2/CO = 2.0$ hedefinin mevcut kontrol sınırları içinde tam olarak yakalanamaması, karar değişkeni sınırlarının, amaç fonksiyonu ağırlıklarının ve gerekirse ek kontrol değişkenlerinin sonraki dönemde daha ayrıntılı incelenmesi gerektiğini göstermektedir.

Bu dönem elde edilen sonuçlar, deneysel olarak doğrulanmış nihai bir proses kontrol sistemi olarak değil, Cantera tabanlı simülasyon verisi üzerinde geliştirilen hesaplamalı bir tahmin-optimizasyon iş akışı olarak değerlendirilmelidir. Geliştirilen kapalı çevrim senaryo, tam dinamik MÖK formülasyonu yerine soft-sensor, ileri vekil model ve tekrarlı optimizasyon

adımlarının birlikte çalışabilirliğini gösteren MÖK-benzeri bir hesaplamalı örnektir. Optimizasyonda kullanılan maliyet terimi gerçek bir enerji veya ekonomik analiz olmayıp sıcaklık, basınç ve buhar/karbon oranına dayalı basitleştirilmiş normalize işletme cezasıdır. BiooilID bazlı ExtraTrees sonucu, nihai MLP soft-sensor modelinin doğrudan validasyonu olarak değil, ters tahmin probleminin yeni biyoyağ kompozisyonlarına karşı genelleme zorluğunu gösteren ek bir denetim olarak yorumlanmalıdır. Ayrıca ters tahmin problemi fiziksel olarak tekil bir çözüm garanti etmediğinden, benzer singaz kompozisyonlarının birden fazla biyoyağ bileşimine karşılık gelebileceği dikkate alınmalıdır. İleri vekil modelin yüksek R2 değeri Cantera simülasyon veri uzayının başarılı biçimde yeniden üretildiğini göstermekte, ancak deneysel reaktör davranışının doğrudan doğrulanması anlamına gelmemektedir. Bu nedenle H₂/CO oranına ek olarak tam gaz kompozisyonu, hidrojen üretimi, karbon içeren ürünler, gazın yaş/kuru baz tanımı ve optimum noktaların değişken sınırlarında bulunması gibi unsurlar nihai tez yazımında ayrıca tartışılacaktır.

B.3 Bir Sonraki Dönem İçerisinde Yapılacak Çalışmalar:

Çalışmanın araştırma ve model geliştirme aşamaları bu dönem itibarıyla tamamlanmıştır. Önceki tez izleme dönemlerinde biyoyağ kompozisyonunun tahminine yönelik veri tabanı oluşturulmuş, veri ön işleme ve makine öğrenmesi modelleri geliştirilmiş, Cantera tabanlı reforming simülasyonları kullanılarak ters makine öğrenmesi modeli kurulmuş ve son dönemde bu model soft-sensor, optimizasyon ve model öngörülü kontrol yapısı içerisinde değerlendirilmiştir. Bu nedenle bir sonraki dönemde yeni bir model geliştirme veya yeni bir hesaplamalı senaryo oluşturma hedeflenmemektedir.

Bir sonraki dönemde yapılacak temel çalışma, bugüne kadar tamamlanan tüm tez izleme raporlarının, üretilen veri setlerinin, yazılım çıktılarının, model performans sonuçlarının, optimizasyon/MÖK senaryolarının, tablo ve figürlerin doktora tezi bütünlüğü içinde yeniden düzenlenmesidir. Bu kapsamda TİK-1 döneminde oluşturulan literatür ve problem tanımı, TİK-2 ve TİK-3 dönemlerinde geliştirilen veri işleme ve ilk makine öğrenmesi modelleri, TİK-4 döneminde geliştirilen Cantera tabanlı ters makine öğrenmesi modeli ve TİK-5 döneminde tamamlanan soft-sensor, ileri vekil model, optimizasyon ve MÖK çalışmaları tek bir tez akışı altında birleştirilecektir.

Tez yazımında öncelikle giriş ve literatür bölümleri güncellenecek, ardından veri seti oluşturma, veri ön işleme, simülasyon altyapısı ve makine öğrenmesi yöntemleri ayrıntılı olarak yöntem bölümüne aktarılacaktır. Bulgular bölümünde önce biyoyağ kompozisyon tahmin

modelleri, ardından ters makine öğrenmesi modeli, BiooilID bazlı validasyon, ileri vekil model performansı, statik optimizasyon sonuçları ve MÖK senaryosu sıralı olarak sunulacaktır. Sonuç bölümünde ise çalışmanın ana katkıları, modelin güçlü yönleri, sınırlılıkları ve gelecekte deneysel doğrulama/veri genişletme çalışmalarıyla nasıl ilerletilebileceği tartışılacaktır.

Bu doğrultuda gelecek dönemin hedefi, tamamlanan bilimsel ve teknik çalışmaları doktora tezinin nihai metnine dönüştürmek, tablo ve figürleri tez formatına uygun hale getirmek, kaynakça ve biçimsel düzenlemeleri tamamlamak ve tezi savunmaya hazır hale getirmektir.

B.4 Kaynaklar Dizini:

Aniza, R., Chen, W., Yang, F., Pugazhendh, A., & Singh, Y. *Integrating Taguchi method and artificial neural network for predicting and maximizing biofuel production via torrefaction and pyrolysis*. Bioresource Technology, 343 (2022): 126140.

AspenTech. *Aspen Plus V12 Documentation*. AspenTech Technical Reference, 1 (2022): 1–1500.

Azri Sukiran, M. M., Institusi, P., Baru Bangi, B., Mee Chin, C., & Kartini Abu Bakar, N. *Bio-oils from Pyrolysis of Oil Palm Empty Fruit Bunches*. American Journal of Applied Sciences, 6(5) (2009): 869–875.

Bekiroğulları, M., & Kaya, M. *Investigation of Hydrogen Production from Bio-Oil Substances Using Aspen Plus*. Gazi University Journal of Science, 33(1) (2020): 14–20.

Bordoloi, N., Narzari, R., Sut, D., Saikia, R., Chutia, R. S., & Kataki, R. *Characterization of bio-oil and its sub-fractions from pyrolysis of Scenedesmus dimorphus*. Renewable Energy, 98 (2016): 245–253. <https://doi.org/10.1016/j.renene.2016.03.081>

Bosch Industrial. *Bio-oil boilers from Bosch are generating future-proof heat*. Şirket Referans Dosyası, (2023): 1–5.

Bridgwater, A. V. (2012). Review of fast pyrolysis of biomass and product upgrading. Biomass and bioenergy, 38, 68-94.

Bridgwater, A., & Peacocke, G. *Fast Pyrolysis Processes for Biomass*. Renewable and Sustainable Energy Reviews, 4 (2000): 1–73.

Cao, B., Yuan, J., Jiang, D., Wang, S., Barati, B., Hu, Y., Yuan, C., Gong, X., & Wang, Q. *Seaweed-derived biochar with multiple active sites as a heterogeneous catalyst for converting macroalgae into acid-free biooil containing abundant ester and sugar substances*. Fuel, 285 (2021). <https://doi.org/10.1016/j.fuel.2020.119164>

Chang, C. C., Chen, C. P., Yang, C. S., Chen, Y. H., Huang, M., & Chang, C. Y. *Conversion of waste bamboo chopsticks to bio-oil via catalytic hydrothermal liquefaction using K₂CO₃*. Chemical Engineering Journal, 288 (2016): 161–172.

Chen, D., Chen, X., Sun, J., Zheng, Z., & Fu, K. *Pyrolysis polygeneration of pine nut shell: Quality of pyrolysis products and study on the preparation of activated carbon from biochar*. *Bioresource Technology*, 216 (2016): 629–636. <https://doi.org/10.1016/j.biortech.2016.05.107>

Chen, D., Cen, K., Jing, X., Gao, J., Li, C., & Ma, Z. *An approach for upgrading biomass and pyrolysis product quality using a combination of aqueous phase bio-oil washing and torrefaction pretreatment*. *Bioresource Technology*, 233 (2017): 150–158. <https://doi.org/10.1016/j.biortech.2017.02.120>

Chen, D., Wang, Y., Liu, Y., Cen, K., Cao, X., & Ma, Z. *Comparative study on the pyrolysis behaviors of rice straw under different washing pretreatments of water, acid solution, and aqueous phase bio-oil by using TG-FTIR and Py-GC/MS*. *Fuel*, 252 (2019): 1–9.

Chen, W., Aniza, R., Arpia, A. A., Lo, H., Hoang, A. T., Goodarzi, V., & Gao, J. *A comparative analysis of biomass torrefaction severity index prediction from machine learning*. *Applied Energy*, 324 (2022): 119689.

Chen, W. H., Huang, M. Y., Chang, J. S., Chen, C. Y., & Lee, W. J. *An energy analysis of torrefaction for upgrading microalga residue as a solid fuel*. *Applied Energy*, 154 (2015): 622–630.

Choi, G. G., & Oh, S. J. *Production of bio-based phenolic resin and activated carbon from bio-oil and biochar derived from fast pyrolysis of palm kernel shells*. *Bioresource Technology*, 178 (2015): 99–107.

Chukwuneke, J. L., Ewulonu, M. C., Chukwujike, I. C., & Okolie, P. C. *Physico-chemical analysis of pyrolyzed bio-oil from Swietenia macrophylla (mahogany) wood*. *Heliyon*, 5(6) (2019): e01790. <https://doi.org/10.1016/j.heliyon.2019.e01790>

Dias, M., & Bezerra, B. *Open-source Process Simulation: DWSIM Capabilities*. *Journal of Chemical Engineering Education*, 54 (2020): 123–130.

Goodwin, D. G., Moffat, H. K., Schoegl, I., Speth, R. L., Weber, B. W. (2017). *Cantera: An object-oriented software toolkit for chemical kinetics, thermodynamics, and transport processes*.

Haq, Z. U., Ullah, H., Khan, M. N. A., Naqvi, S. R., Ahad, A., & Amin, N. A. S. *Comparative study of machine learning methods integrated with genetic algorithm and particle swarm optimization for bio-char yield prediction*. *Bioresource Technology*, 363 (2022): 128008.

Hu, Z., Zhu, L., Cai, H., Huang, M., Li, J., & Cai, B. *Enhancement of the production of bio-aromatics from bamboo pyrolysis: Wet torrefaction pretreatment coupled with catalytic fast pyrolysis*. *Journal of Analytical and Applied Pyrolysis*, 169 (2023): 105818.

Hwang, H., Oh, S., Cho, T., Choi, I., & Choi, J. W. *Fast Pyrolysis of potassium impregnated poplar wood and characterization of its influence on the formation as well as properties of pyrolytic products*. *Bioresource Technology*, 150 (2013): 359–366.

Inayat, A., & Dahoe, A. *Integrated WGS Reactor Modeling*. *Catalysis Today*, 249 (2015): 206–214.

Kartal, F., & Özveren, U. *Prediction of torrefied biomass properties from raw biomass*. Renewable Energy, 182 (2022): 578–591.

Keskin, T., & Duman, G. *Bioethanol production by syngas fermentation from pyrolysis gas using mixed culture: Heat-pretreatment effect*. Pamukkale Üniversitesi Mühendislik Bilimleri Dergisi, 26(7) (2020): 1299–1307.

Khor, K. H., Lim, K. O., & Zainal, Z. A. *Characterization of Bio-Oil: A By-Product from Slow Pyrolysis of Oil Palm Empty Fruit Bunches*. American Journal of Applied Sciences, 6(9) (2009): 1647–1652.

Kutlu, Ö., & Koçar, G. *Upgrading lignocellulosic waste to fuel by torrefaction: Characterisation and process optimization by response surface methodology*. International Journal of Energy Research, 42 (2018): 4746–4760.

Lee, H., & Kim, Y. M. *Recent advances in the catalytic hydrodeoxygenation of bio-oil*. Korean Journal of Chemical Engineering, 33(12) (2016): 3299–3315.

Leng, E., He, B., Chen, J., Liao, G., Ma, Y., Zhang, F., Liu, S., & E, J. *Prediction of three-phased product distribution and bio-oil heating value of biomass fast pyrolysis based on machine learning*. Energy, 236 (2021): 121401.

Leng, E., He, B., Chen, J., Liao, G., Ma, Y., Zhang, F., Liu, S., & E, J. (2021). Prediction of three-phase product distribution and bio-oil heating value of biomass fast pyrolysis based on machine learning. *Energy*, 236. <https://doi.org/10.1016/j.energy.2021.121401>

Luyben, W. *Process Design of Steam-Methane Reformers*. Industrial & Engineering Chemistry Research, 55 (2016): 2486–2498.

Modak, S., Katiyar, P., Yadav, S., Jain, S., Gole, B., & Talukdar, D. *Generation and characterization of bio-oil obtained from the slow pyrolysis of cooked food waste at various temperatures*. Waste Management, 158 (2023): 23–36. <https://doi.org/10.1016/j.wasman.2023.01.002>

Mullen, C. A., Boateng, A. A., Hicks, K. B., Goldberg, N. M., & Moreau, R. A. *Analysis and comparison of bio-oil produced by fast pyrolysis from three barley biomass/byproduct streams*. Energy & Fuels, 24(1) (2010): 699–706. <https://doi.org/10.1021/ef900912s>

Ni, M., & Leung, D. Y. C. *An Overview of Hydrogen Production from Biomass*. Fuel Processing Technology, 87 (2006): 461–472.

Nzihou, A., Stanmore, B., Lyczko, N., & Minh, D. P. *The catalytic effect of inherent and adsorbed metals on the fast/flash pyrolysis of biomass: a review*. Biomass and Bioenergy, 116 (2014): 358–369.

Oasmaa, A., & Peacocke, C. (2010). A guide to physical property characterisation of biomass-derived fast pyrolysis liquids. VTT Publications.

Onsree, T., & Tippayawong, N. *Machine learning application to predict yields of solid products from biomass torrefaction*. Renewable Energy, 167 (2021): 425–432.

Pafili, A., Charisiou, N. D., Douvartzides, S. L., Siakavelas, G. I., Wang, W., Liu, G., Papadakis, V. G., & Goula, M. A. (2021). Recent progress in the steam reforming of bio-oil for hydrogen production: A review of operating parameters, catalytic systems and technological innovations. In *Catalysts* (Vol. 11, Issue 12). MDPI. <https://doi.org/10.3390/catal11121526>

Sampaio, T. Q. S., Lima, S. B., & Pires, C. A. M. *Influence of extractives on the composition of bio-oil from biomass pyrolysis – A review*. Journal of Analytical and Applied Pyrolysis, 186 (2025): 106919. <https://doi.org/10.1016/j.jaap.2024.106919>

Sharifzadeh, M., & Sadeqzadeh, M. *The multi-scale challenges of biomass fast pyrolysis and bio-oil upgrading: Review of the state of art and future research directions*. Progress in Energy and Combustion Science, 71 (2019): 1–80.

Singh, P. P., & Jaswal, A. *Green hydrogen production from biomass – A thermodynamic assessment of the potential of conventional and advanced bio-oil steam reforming processes*. International Journal of Hydrogen Energy, 50 (2024): 627–639.

Smith, J., & Brown, P. *Dynamic Simulation and MPC Design for Steam Reformers*. Chemical Engineering Research and Design, 149 (2019): 174–186.

Smith, W. R., & Missen, R. W. (1982). Chemical reaction equilibrium analysis: Theory and algorithms. Letchworth, Hertfordshire, UK: Research Studies Press.

US Forest Service. *Replacing Fossil Fuels in Community Heating Boiler with Bio-oil*. Community Wood Energy & Innovation Program Report, (2021): 1–10.

Vagia, E. C., & Lemonidou, A. A. (2007). Thermodynamic analysis of hydrogen production by steam reforming of bio-oil components. International Journal of Hydrogen Energy, 32(2), 212–223.

Varun Kumar, T. H., & Mayakrishnan, M. *Evaluation of the properties of bio-asphalt derived from waste cooking oil and low-density polyethylene through the pyrolysis process*. Case Studies in Construction Materials, 21 (2024): e03604.

Wang, S., & Jiang, W. *Catalytic Steam Reforming of Bio-oil Model Compounds*. Energy & Fuels, 27 (2013): 415–423.

Wang, S., Li, Z., Bai, X., Yi, W., & Fu, P. *Influence of inherent hierarchical porous char with alkali and alkaline earth metallic species on lignin pyrolysis*. Bioresource Technology, 268 (2018): 323–331. <https://doi.org/10.1016/j.biortech.2018.07.117>

Wright, M. M., Daugaard, D. E., Satrio, J. A., Brown, R. C., (2010). Techno-economic analysis of biomass fast pyrolysis to transportation fuels. Fuel, 89, S2–S10.

Xu, J., & Brodu, N. *Synthesis and characterization of phenolic resins based on pyrolysis bio-oil separated by fractional condensation and water extraction*. Biomass and Bioenergy, 159 (2022): 106393.

Yang, H., Yan, R., Chen, H., Lee, D. H., & Zheng, C. *Characteristics of hemicellulose, cellulose and lignin pyrolysis*. Fuel, 86(12-13) (2007): 1781–1788.

Yang, Y., & Xu, X. *The catalytic hydrodeoxygenation of bio-oil for upgradation from lignocellulosic biomass*. International Journal of Biological Macromolecules, 242 (2023): 124773–124789.

Zhang, M., & Hu, Y. *A review of bio-oil upgrading by catalytic hydrotreatment: Advances, challenges, and prospects*. Molecular Catalysis, 504 (2021): 111438.

Zhang, S., Chen, T., Xiong, Y., & Dong, Q. *A comprehensive review of bio-oil, bio-binder and bio-asphalt materials: Their source, composition, preparation and performance*. Journal of Traffic and Transportation Engineering (English Edition), 9(2) (2022): 151–166.

Zhang, Z., Fang, Y., * omitted methods from original file if any *

Zhu, X., Yinan, L., & Wang, X. *Machine Learning prediction of biochar yield and carbon contents in biochar based on biomass characteristics and pyrolysis conditions*. Bioresource Technology, 288 (2019): 121527.

Zhu, Z., Toor, S. S., Rosendahl, L., Yu, D. H., & Chen, G. Y. *Influence of alkali catalyst on product yield and properties via hydrothermal liquefaction of barley straw*. Journal of Cleaner Production, 80 (2015): 284–292.